# 跨神经系统的训练—学习—推理—强化统一动力学

Mian Wang

武汉轻工大学，中国湖北武汉

通讯作者：wangmian945@gmail.com

中文对照译稿，仅供作者审阅；科学引文、正式投稿及术语裁决以英文原稿为准。原始图中的英文标注保持不变。

## 摘要

尽管训练、学习、推理和强化已得到广泛研究，但它们各自的动力学角色及其相互联系仍缺乏统一的实验性刻画。九项 nanoGPT 实验建立了训练—学习—推理（TLI）动力学关系：真实更新引起依赖接收状态的有限幅度功能响应；学习表现为分布式功能支撑的持久重组；目标跨越其特异性读出边界时，才会发生可观察的能力状态转变；推理则在不改变已学习状态的条件下调用这些支撑。第五项实验识别出的因素导出了一种直接预测更新后能力转变的算法，在 5,088 个目标上达到 91.43% 的准确率和 91.49% 的四类别宏平均召回率。随后，我们在另外五种神经网络架构中检验了这些关系及其预测。在第七种系统中，集中分配正确反馈削弱了其他已经掌握的技能；重新均衡反馈使这些技能的准确率从 70.31% 恢复至 99.48%。将推理产生的后果与后续训练连接起来，便形成统一的训练—学习—推理—强化（TLIR）闭环动力学。

## 1 引言

训练、泛化、能力形成和推理是神经网络研究的核心问题。不同研究领域已经发展出具有重要影响力的理论来研究这些问题。

在**优化理论**中，神经切线核（Neural Tangent Kernel，NTK）通过网络雅可比矩阵及相应的核，描述特定训练区域内参数变化引起的输出变化 (1)。边缘稳定性（Edge of Stability）研究训练行为与 Hessian 最大特征值、学习率及损失轨迹之间的关系 (2)。锐度感知最小化（Sharpness-Aware Minimization，SAM）利用参数邻域内的损失变化构造训练更新，以改善泛化性能 (3)。在这些研究中，当前状态由参数及其局部导数或曲率表示；真实更新由优化器产生；响应则表现为模型输出或损失的变化。

在**表征学习与泛化**中，频谱偏置（Spectral Bias）考察函数或核模态随频率而异的学习速度 (4)。隐式偏置（Implicit Bias）研究优化器为何会选择特定的解，例如可分数据上的最大间隔方向 (5)。神经坍缩（Neural Collapse）测量类别特征均值、类内变异性和分类器几何结构，揭示训练准确率达到饱和后表征仍可继续变化 (6)。信息瓶颈（Information Bottleneck）理论研究输入、隐藏表征和目标之间的互信息，包括任务相关信息的保留与压缩 (7)。这些研究中的内部组织表现为频谱模态、优化器选择的解、特征几何或信息结构；功能变化则表现为学习速度、解的演化和预测表现的变化。

在**能力形成**研究中，Grokking 描述了拟合训练样本与取得较强测试泛化能力之间的长时间延迟 (8)。后续计算回路研究追踪了这一延迟期间内部计算结构的形成和重组 (9)。双重下降（Double Descent）研究测试误差如何在接近插值区域时上升，并随模型规模、训练时间或数据条件变化而再次下降 (10, 11)。这些研究利用训练阶段或插值区域表征当前状态，利用计算回路与解的演化表征内部变化，并通过准确率和泛化误差衡量可观察能力。

在**持续学习**中，灾难性遗忘是指新任务训练降低了先前任务的表现。弹性权重巩固（Elastic Weight Consolidation，EWC）使用先前任务的 Fisher 信息估计参数重要性，并惩罚重要参数的改变 (12)。梯度情景记忆（Gradient Episodic Memory，GEM）使用新任务梯度与先前任务梯度的内积约束新任务更新 (13)。正交梯度下降（Orthogonal Gradient Descent，OGD）则将新梯度投影到能够近似保持先前任务输出的方向 (14)。在这些方法中，已有状态包含之前形成的参数和对函数变化敏感的方向；更新是受到约束的新任务动作；相互作用通过重叠的梯度或功能子空间产生；能力变化通过保持、遗忘或迁移进行测量。

在**推理研究**中，注意力机制（Attention）利用查询（Query）、键（Key）和值（Value）计算依赖输入的信息权重 (15)。上下文学习（In-context Learning）研究在模型参数固定时，上下文中的示例和任务信息如何影响预测 (16)。思维链提示（Chain-of-Thought Prompting）研究中间推理步骤如何影响复杂任务表现 (17)。当前状态是已训练模型；输入条件包括查询、上下文和中间计算；内部计算随注意力和激活状态改变；功能表现则通过预测结果观察。

在**强化与反馈驱动训练**中，基于人类反馈的强化学习（Reinforcement Learning from Human Feedback，RLHF）利用偏好和奖励信号调整模型行为 (18)。自训练（Self-training）进一步使用模型预测生成训练数据 (19)。递归模型坍塌研究考察连续几代模型使用前代生成的数据进行训练时，低概率模态逐渐丧失的现象 (20)。这里，反馈由奖励、偏好或生成数据分布提供；训练动作是由此产生的更新；随后的功能变化通过行为、准确率和生成分布的变化加以观察。

上述研究使用了不同的数学对象——核、Hessian 矩阵、梯度、类别特征、互信息、任务得分、注意力权重与奖励信号——但仍可识别出六类反复出现的共同变量：当前状态、真实更新、功能响应、内部组织、可观察能力和反馈。TLIR 的核心关系是在开展上述跨领域比较之前，通过实验建立的；这里识别这些共同变量，是为了帮助读者理解理论，而

不是描述理论最初的发现过程。

图 1 展示了相互连接的四种动力学角色。

# 2 TLI 开环动力学的实验建立

用于建立 TLI 的九项 nanoGPT 实验，所包含的原生干预、受控对照和独立验证，远比正文所能完整呈现的范围更广。本节概述这些实验的主要发现及由此建立的理论关系。完整实验协议、执行记录、负面结果和独立验证程序均保存在配套仓库中。

## 2.1 实验仪器与证据控制

这些实验所需的仪器，是随着具体测量问题的出现而逐步开发的，并非在理论建立之前就预先假定其存在。

这些仪器共同依托生成事实图（Generation-Fact Graph，GFG），它把记录的模型与优化器状态、真实更新事件、干预、输出及其来源身份连接起来。对于**训练**，真实更新因果分叉仪器恢复匹配的接收状态，对比完整更新、跳过更新、仅参数更新、优化器记忆变化和双向移植分支，从而区分更新本身与接收该更新的状态的作用。随后，有限幅度响应路径仪器将同一条已记录的真实更新，以预先冻结的不同幅度施加于模型，测量非线性数值响应和离散状态转变。对于**学习**，CSRG-4C 通过重复基线、单组件门控和双组件门控，测量已注册目标组功能支撑的必要性、备份、替代、协同作用及失效余量。最后，身份对齐目标边界账本把每个注册目标与精确的更新前状态和真实更新相对应，并将响应发生前的记录与更新后正确性的裁决分离。冻结协议、负面对照和独立验证程序进一步约束了对实验结果的解释。

## 2.2 训练：真实更新与接收状态

在一个已注册的训练步骤中，参数—优化器状态为 $Z_t = (\theta_t, \omega_t)$，真实参数更新定义为 $\Delta\theta_t = \theta_{t+1} - \theta_t$。

TL-E01 揭示了能力形成、下降和恢复现象，而这些现象不能仅通过损失、准确率或训练步数得到完整刻画。TL-E02 进一步表明，暂停有效的参数—优化器演化会延迟能力形成，而梯度裁剪阈值的对照实验并未复现这一效应。

TL-E03 使用完整更新/跳过更新分支及双向更新移植，建立了如下关系：相同真实更新作用于不同接收状态时，会产生不同的功能响应：

$$R_q(\theta_A, \Delta\theta_B) \quad \text{vs.} \quad R_q(\theta_B, \Delta\theta_B), \tag{1}$$

其中 $R_q(\theta, \Delta) = m_q(\theta + \Delta) - m_q(\theta)$。另行开展的优化器记忆交换检验了历史优化器状态如

何影响更新的形成：

$$\Delta^{(a,b)} = \mathrm{OptStep}(\theta_t, g_t, \omega_{a,b}). \tag{2}$$

TL-E04 测量了一次真实更新所产生的完整有限幅度响应：

$$r_{t,q}(\alpha) = m_q(\theta_t + \alpha\Delta\theta_t) - m_q(\theta_t). \tag{3}$$

实验识别出近线性、饱和、加速、回转和符号反转等响应形式。随后，TL-E05 识别出三类主要响应条件因素：目标边界状态（F1）、目标特异性更新几何（F3）和参数—优化器接收状态（F5）。

## 2.3 学习：分布式功能支撑与能力边界

TL-E06 通过可逆的组件干预，建立了分布式功能支撑的实验证据，包括组件必要性、备份、替代、协同作用和失效余量。

随后，TL-E07 检验了真实训练更新如何持续重组这些支撑：

$$\Delta P_{t,q} = P_q(\theta_t + \Delta\theta_t) - P_q(\theta_t). \tag{4}$$

在 72 个实验区段中，记录了 1,636 次有效的支撑分配转变和 228 次主要支撑组件交接。

TL-E08 通过身份对齐的目标读出边界，将这些内部变化与可观察的能力联系起来。更新前后间隔（margin）的符号用于区分能力保持、丧失、未获得及获得或恢复。因此，学习被界定为**持久的功能支撑重组**，而能力转变由目标特异性读出边界的跨越决定。

## 2.4 推理：冻结状态下对已学习支撑的调用

INF-E01 研究了 13 条 nanoGPT 训练历史和 52 个检查点。在持久学习状态冻结的条件下，实验测量了依赖查询条件的组件效应、非加性的支撑交互，以及将已训练组件替换为其能力形成前的精确历史版本所产生的变化。

在固定的学习状态 $L^*$ 下，推理调用并组合已经学习形成的支撑：

$$S_{q,c}^{\mathrm{active}} = \Pi_{q,c}(L^*), \qquad y_{q,c} = H_{q,c}(S_{q,c}^{\mathrm{active}}). \tag{5}$$

组件之间的非加性交互通过下式测量：

$$I_{ij,q} = f_{\mathrm{full}} - f_{-i} - f_{-j} + f_{-i,-j}, \tag{6}$$

而对已学习组件版本的依赖通过下式检验：

$$D_{j,q} = f(q;\theta^*) - f(q;\theta^{(j\leftarrow \mathrm{pre})}). \tag{7}$$

精确恢复证明，这些干预并未持续改变已学习状态。实验由此建立了推理的动力学定义：**推理是在查询条件下调用并组合学习形成的功能支撑，而持久学习状态保持冻结**。

上述九项实验共同建立了相互连接的训练—学习—推理关系，形成 TLI 开环动力学。图 2 汇总了 TLIR 四种动力学角色的实验依据。

# 3　预测与跨系统验证

## 3.1　由理论导出的目标边界预测

TL-E05 的响应因素分析确定了三类主要条件因素：当前目标边界状态（F1）、目标特异性更新几何（F3）和参数—优化器接收状态（F5）。这些发现直接导出了 TL-P01 算法，用于预测一次已经形成的真实更新之后，目标的即时边界结果。

对于目标 $y$、竞争目标 $c$ 和隐藏表征 $h$，定义 $b_c = w_y - w_c$ 和 $\Delta b_c = \Delta w_y - \Delta w_c$。利用一阶方向导数 $h' = Dh[\Delta\theta_t]$ 和二阶方向导数 $h'' = D^2h[\Delta\theta_t, \Delta\theta_t]$，预测器计算：

$$\begin{aligned}\widehat{g}_{y,c} = {} & b_c^\top h + \Delta b_c^\top h + b_c^\top h' \\ & + \Delta b_c^\top h' + \tfrac{1}{2} b_c^\top h''.\end{aligned} \tag{8}$$

当 $\min_{c \neq y} \widehat{g}_{y,c} > 0$ 时，预测该目标在更新后正确。将预测的更新后正确性与已知的更新前状态结合，即可得到四类能力转变。预测使用的是已经形成的真实更新和响应发生前的信息，**不读取目标在实际更新后的真实输出**。

## 3.2　跨系统验证

随后，我们在另外五种神经系统中检验了已经建立的 TLI 关系及其预测性结果。表 1 汇总本研究的七种系统，其中第七种 GRU 系统用于单独进行强化反馈实验。

对于另外五种 TLI 系统，分别开展真实更新干预、接收状态比较、有限幅度响应测量、组件联盟功能支撑测量、目标边界结果判定和冻结推理检验。跨系统实现枚举四个注册组件形成的全部 16 种联盟，并计算精确的 Shapley 效应：

$$\phi_{j,q} = \sum_{C \subseteq \mathscr{C} \setminus \{j\}} \frac{|C|!(3-|C|)!}{4!} \left[ v_q(C \cup \{j\}) - v_q(C) \right]. \tag{9}$$

这里，$v_q(C)$ 表示组件联盟 $C$ 激活时的目标间隔（margin）。

在 ResNet、扩散 U-Net 和 Vision-MoE 中，分别有 42 次、18 次和 36 次参数接收状态交换，其响应差异均超过了预先注册的阈值。各自的目标—更新记录中，有限幅度非线性响应的发生比例分别为 32.23%、19.25% 和 35.71%；功能支撑重分配超过规定阈值的比例则分别为 91.41%、97.02% 和 80.43%。各系统中的冻结推理实验进一步确认了依赖查询条件的功能支撑、非加性交互及对精确训练后组件版本的依赖。

GNN 在三个随机种子中复现了主要 TLI 关系，但其中一个种子未达到预先注册的非线性响应发生频率判据（1.56%）。硬脉冲 SNN 在四个随机种子中均通过全部 12 项已注册 TLI 判据，从而将证据扩展到具有不连续脉冲动力学的系统。

研究还根据不同任务对方向响应计算作了适配，并在这些系统中评价预测算法。表 2 给出了更新后即时目标边界分类结果。

预测器在六种 TLI 系统中的五种上取得了较高的四类别宏平均召回率。在硬脉冲 SNN 中，不连续的激活阈值限制了基于局部导数的预测：尽管准确率达到 95.31%，四类别宏平均召回率仅为 70.74%。这些实验表明，TLI 核心关系能够跨系统反复出现，同时不同架构在定量功能响应和预测近似方面存在差异。图 3 汇总了六种系统各自的 TLI 实验关系链。

# 4 强化：从 TLI 开环动力学到 TLIR 闭环动力学

## 4.1 由理论导出的反馈动力学预测

已经建立的 TLI 关系表明，训练会持久重组分布式功能支撑，而推理则调用、组合这些已学习支撑来产生行为。如果推理产生的后果反复反馈到后续训练中，那么由此产生的更新就能进一步重组未来推理所依赖的支撑。

由此得出一项预测：持续、狭窄地集中分配**正确的正反馈**，可能逐步有利于被强化的能力，同时削弱其他已经掌握的能力。该预测效应来自反馈引导的功能重组，而非错误奖励。

## 4.2 实验检验与结果

RL-E05/E06 在第七种系统——一个不含注意力机制的共享 GRU 策略网络中——检验了这项预测。全部四项技能都在实验分支开始前达到掌握标准。每个分支都从完全相同的参数—AdamW 状态出发；每个完整的两次决策回合仅在正确时获得 $r = 1$，否则 $r = 0$。

RL-E05 比较了选择性、均衡和冻结反馈。RL-E06 则在 3,200 次更新中改变每次更新 60 个回合的分配方式（表 3）。

RL-E05 观察到相对功能支撑集中、跨技能干扰和依赖组件历史版本的能力权衡，但其预先注册的、更严格的时间先后关系判据**未能满足**。

在 RL-E06 中，全部 12 个正式随机种子均呈现随反馈集中程度变化的剂量有序效应。被强化技能的平均支撑份额从均衡反馈的 25.54% 增加到独占反馈的 35.20%，其他技能的平均间隔则从 9.474 降至 3.962。在轻度和高度集中反馈下，即使准确率尚未下降，其他技能的间隔已开始减小。与均衡反馈相比，独占反馈使其他技能的准确率降低了 39.06 个百分点。

随后，从第 800 次更新时精确的独占反馈状态出发建立两条恢复分支。重新均衡反馈使其他技能的平均准确率从 70.31% 恢复至 99.48%，同时将被强化技能保持在 100%。只训练另外三项技能也使其准确率恢复至 99.83%，但之前被强化的技能下降至 89.06%。

这些实验表明，在所测试的共享系统中，正确反馈的分配方式能够重新引导持久功能支撑、改变先前已掌握的能力，并通过反馈重新分配逆转这些变化。

### 4.3 TLIR 闭环动力学

强化把推理产生的后果连接到后续训练动作。由此产生的训练更新重组已学习支撑，进而改变未来推理及其后果。这一反馈闭环将实验建立的 TLI 开环动力学转化为统一的训练—学习—推理—强化（TLIR）闭环动力学。

## 5 对正面与负面研究结果的统一解释

**独立的历史正反压力测试**。只有在实验建立 TLI 并完成强化反馈闭环之后，我们才将 TLIR 与既有文献中的 21 组正反结果进行比较。这些文献并不是 TLIR 的理论设计素材。检验的问题是：同一套“接收状态—动作—响应—支撑—边界—反馈”关系，能否同时解释一个局部理论为何成立，以及它越出适用范围后为何失效。每一组比较都需要指出具体改变的机制、内部实验锚点和可能的反证条件；仅仅说“条件不同”并不充分。这些历史比较提供的是外部解释性趋同，而不是原研究者对 TLIR 的新因果验证。

**训练：核动力学与特征形成**。神经切线核（NTK）能够严格描述特定无限宽度、惰性训练区域的动力学 (1)，而特征学习参数化则允许表征发生实质性演化 (21)。两者都可能成立，因为参数化方式与接收状态共同决定真实更新的功能响应。TL-E03 的双向更新移植与 TL-E04 的有限幅度响应路径为这一划分提供了实验锚点。某个局部区域中的精确核描述，并不意味着能够普遍闭合真实有限更新及不断演化的功能支撑。反过来，若固定核能够跨不同接收状态和真实更新稳定闭合有限响应，便会对这种解释构成挑战。

**学习：延迟出现的能力与持续的内部形成**。 Grokking 表现为训练性能饱和很久以后测试泛化能力才出现 (8)；对其计算回路的分析表明，在可观察转变发生之前，内部结构已经历形成过程 (9)。神经坍缩研究也记录了训练误差降为零以后特征组织仍在继续演化 (6)。TL-E07/E08 明确区分持久功能重组与目标特异性读出：内部支撑和间隔可以持续改变，而离散准确率指标保持不变，直到状态跨越相应边界。因此，学习既不必从某一个准确率阈值开始，也不会因为跨过该阈值而自动停止。

**推理：注意力的因果作用与注意力权重解释之间的区别**。注意力机制实现了依赖查询的信息组合 (15)。然而，注意力权重未必与特征重要性指标一致，也可能在输出没有相应变化时发生明显改变 (22)；另一组受控检验又表明，这并不意味着注意力在所有情况下都毫无解释价值 (23)。这些结论针对的并不是同一个解释对象。INF-E01 通过精确历史版本回退、组件门控和非加性成对交互，建立了冻结推理对被调用的已学习功能支撑的因果依赖，但没有把某一张注意力权重图等同于完整支撑结构。真正接受检验的是经过干预定义的功能支撑关系，而不是某一种归因分数。

**强化：正确反馈与跨能力权衡**。基于偏好的反馈能够改善目标行为 (18)，但被强化目标上的成功，并不保证共享系统的其他功能得到保持。RL-E06 使用的是正确任务奖励，而不是错误设置的代理奖励：随着反馈逐渐集中，功能支撑系统性地重新分配，未强化技能的间隔下降；重新均衡反馈又逆转了相当一部分损失。RL-E05 中预先注册的、更严格的

时间先后判据未被满足；这一失败不能与随后通过的剂量—持续时间—恢复关系混为一谈。因此，局部有益的反馈过程可以在系统层面具有双刃剑效应，但这并不等于所有强化学习系统都会表现相同。另外一些历史正反案例还将锐度与 SAM (3, 24)、信息瓶颈压缩 (25, 26) 定位为特定条件下可能有效的局部机制，而非所有学习过程必需的完整解释。

**理论先行的有条件外推**。不同于上述历史文献比较，我们还从实验建立的 TLIR 关系出发，先推导有条件的理论结果，再检索相应文献。这样的“先推导、后检索”程序并不等同于真正盲法的前瞻性预注册。因此，与独立研究结果一致能够支持这些推导的适用范围，却不意味着被引用的论文直接检验了 TLIR 整体。

*演化中的稳定性*。对参数空间中的普通梯度下降，在局部二次损失近似下，一个正曲率的冻结 Hessian 模态具有单步因子 $1-\eta\lambda_i$，因此局部稳定条件为 $|1-\eta\lambda_i|<1$，上边界为 $\lambda_i = 2/\eta$。TLIR 将这一条件置于持续演化的“接收状态—动作”映射之中：有限幅度更新和优化器记忆会改变后续曲率与响应，所以瞬时越过冻结的局部稳定边界，并不能单独证明长期真实训练必然发散。已有的边缘稳定性轨迹提供了可对照的外部结果 (2)。

*能力形成后的继续学习*。在线性可分的 logistic 分类中，即使全部目标间隔 $m_i = y_i w^\top x_i$ 都已经为正，梯度仍可非零。间隔较大时，残余训练动作对样本的权重近似正比于 $e^{-m_i}$，从而更加重视接近读出边界的样本。在相应线性可分性和损失尾部条件下，持续训练将选择最大间隔方向 (5)。这是由“可观察正确性”与“持久学习”之间的区别导出的条件性结果，并不是说所有神经网络架构都收敛到同一条间隔定律。

*递归反馈*。若连续几代模型生成的训练数据只按 $0<\rho<1$ 的比例保留某一信息模态，并完全替换旧数据，该模态的质量就会收缩。若每代持续引入比例为 $\alpha$、且该模态质量为 $q_{\text{real}}>0$ 的外部真实数据，则有以下条件性递推：

$$q_{t+1} = (1-\alpha)\rho q_t + \alpha q_{\text{real}}. \tag{10}$$

当 $\alpha = 0$ 时，该模态持续衰减；当 $\alpha > 0$ 时，其质量趋向正的固定点 $q^* = \alpha q_{\text{real}}/[1-(1-\alpha)\rho] > 0$。因此，有益自训练、递归生成数据造成的分布尾部丢失，以及持续加入真实数据产生的保护作用 (19, 20, 27)，可以对应同一反馈闭环的不同区域，而不必彼此矛盾。

这些外推明确规定假设与适用边界，而不是声称存在普适数值定律。我们欢迎审稿人和其他独立研究者从 TLIR 出发，继续推导新的有条件预测，事先说明哪些结果能够证伪这些预测，并在新的系统中开展独立检验。

# 6 结论

通过跨神经系统的系统性实验，本研究揭示了贯穿神经网络训练、学习、推理和强化过程的动力学关系。从能力形成与使用到能力丧失与恢复，TLIR 在可观察性能变化与内部功能支撑的组织及其演化之间，建立了能够通过实验检验的因果联系。因此，神经网络能力演化不再只是一种黑箱性能现象，而成为能够通过精确实验干预和定量预测加以研究的动力学过程。

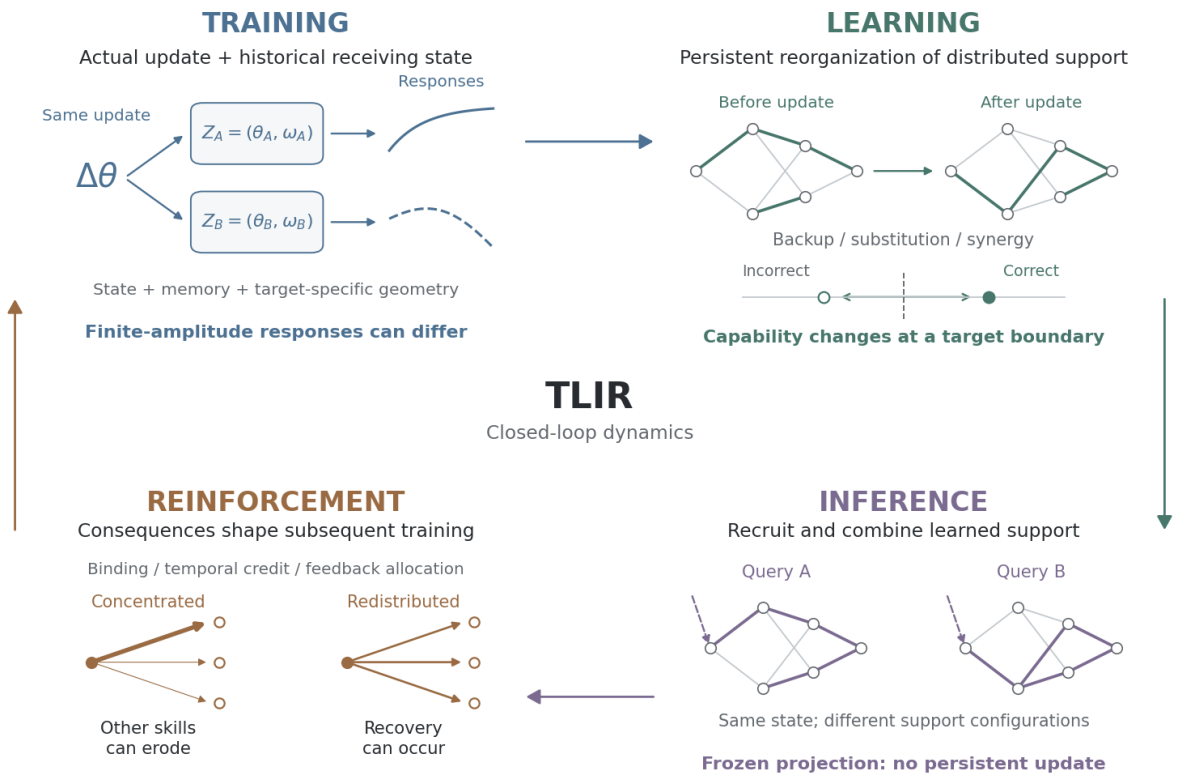



**图** 1. TLIR 闭环动力学。训练、学习和推理构成开环核心；强化则将模型行为产生的后果反馈至后续训练，从而形成闭环。

**表** 1. 七种神经系统：六条 TLI 实验链及一项 GRU 反馈研究。

| 系统（优化器） | 任务 / 注册组件 |
|---|---|
| nanoGPT（Adam） | 循环式下一词元预测；4 个注意力 / MLP 分支 |
| ResNet-18（SGD momentum） | CIFAR-100 分类；4 个残差阶段 |
| Diffusion U-Net（AdamW） | CIFAR-10 去噪；4 条 U-Net 路径 |
| Vision-MoE（AdamW） | CIFAR-100 分类；4 个路由专家 |
| GNN（RMSprop） | 图可达性判断；4 个消息传递模块 |
| Spiking SNN（Adagrad） | $8 \times 8$ 数字图像；4 个脉冲模块 |
| GRU（RL-E05/E06；AdamW） | 四技能反馈；4 个共享隐藏状态组 |




**图** 2. nanoGPT 中训练、学习和冻结推理的代表性实验证据，以及共享 GRU 中反馈驱动的能力变化与恢复。(a1) 暂停演化延迟能力形成；(a2) 相同真实更新在不同接收状态下引起不同响应；(a3) 有限幅度响应的不同类型；(a4) 边界、更新和接收状态三类条件因素。(b1) 联合移除组件导致目标跨越边界；(b2) 一次真实更新引起功能支撑重新分配；(b3) 更新前后的目标间隔。(c1) 查询条件依赖的组件效应；(c2) 非加性成对交互；(c3) 已学习组件版本回退与精确恢复。(d1) 反馈剂量下的支撑重分配；(d2) 准确率下降前的间隔侵蚀；(d3) 回退引起的能力权衡；(d4) 反馈重新均衡及能力恢复。

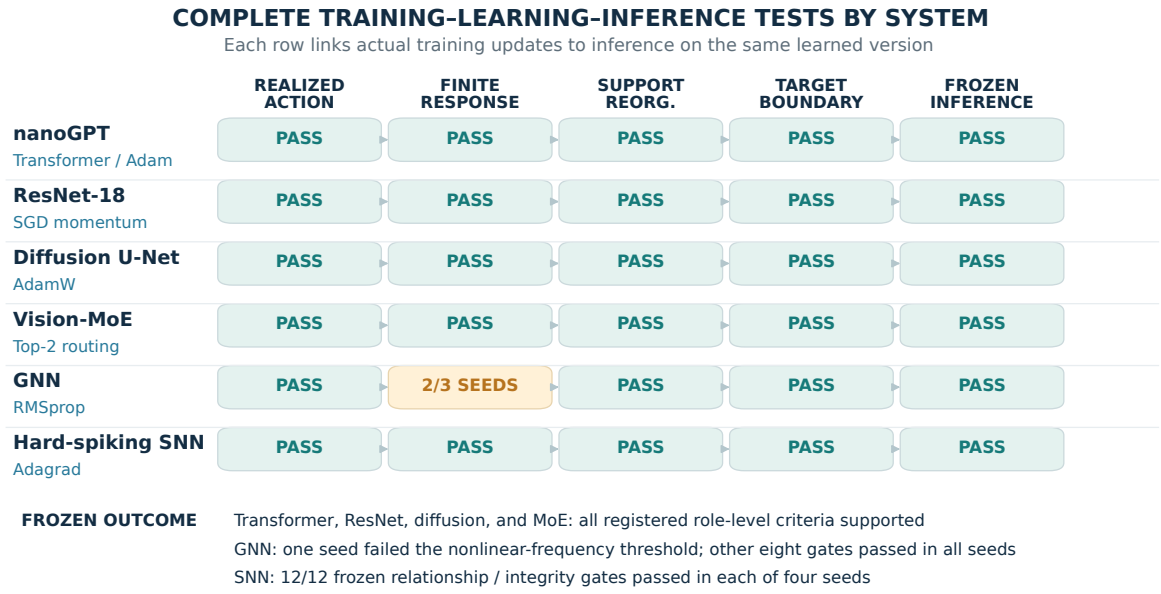



**图** 3. 六种神经系统各自内部的训练—学习—推理实验关系链。GNN 中有一个随机种子满足九项注册判据中的八项，其非线性响应发生频率低于规定阈值；SNN 在四个随机种子中全部通过十二项注册判据。

**表** 2. 更新后目标边界分类结果。宏平均召回率为四种实际观察到的能力转变类别的平均召回率；仅有较高准确率并不足以说明预测性能。各系统的预测方法细节与评价集合有所不同。

| 系统 | 准确率（%） | 四类别宏平均召回率（%） |
|---|---|---|
| nanoGPT | 91.43 | 91.49 |
| ResNet-18 | 99.28 | 97.99 |
| Diffusion U-Net | 99.60 | 97.98 |
| Vision-MoE | 99.63 | 96.95 |
| GNN[a] | 98.54 | 98.62 |
| Hard-spiking SNN[a] | 95.31 | 70.74 |

[a] GNN 与 SNN 的独立预测检验使用已注册的训练历史。

**表** 3. RL-E06 每次更新中分配给四项能力的反馈回合数。

| 反馈方式 | $q_0$ | $q_1$ | $q_2$ | $q_3$ |
|---|---|---|---|---|
| 均衡（Balanced） | 15 | 15 | 15 | 15 |
| 轻度集中（Mild） | 30 | 10 | 10 | 10 |
| 高度集中（High） | 45 | 5 | 5 | 5 |
| 独占（Exclusive） | 60 | 0 | 0 | 0 |

# 参考文献与注释


1. A. Jacot, F. Gabriel, C. Hongler, Neural tangent kernel: Convergence and generalization in neural networks. Adv. Neural Inf. Process. Syst. 31 (2018).
2. J. M. Cohen, S. Kaur, Y. Li, J. Z. Kolter, A. Talwalkar, Gradient descent on neural networks typically occurs at the edge of stability. Proc. ICLR (2021).
3. P. Foret, A. Kleiner, H. Mobahi, B. Neyshabur, Sharpness-aware minimization for efficiently improving generalization. Proc. ICLR (2021).
4. N. Rahaman, A. Baratin, D. Arpit, F. Draxler, M. Lin, F. A. Hamprecht, Y. Bengio, A. Courville, On the spectral bias of neural networks. Proc. Mach. Learn. Res. 97, 5301–5310 (2019).
5. D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, N. Srebro, The implicit bias of gradient descent on separable data. J. Mach. Learn. Res. 19, 1–57 (2018).
6. V. Papyan, X. Y. Han, D. L. Donoho, Prevalence of neural collapse during the terminal phase of deep learning training. Proc. Natl. Acad. Sci. U.S.A. 117, 24652–24663 (2020).
7. N. Tishby, N. Zaslavsky, Deep learning and the information bottleneck principle. IEEE Information Theory Workshop, arXiv:1503.02406 (2015).
8. A. Power, Y. Burda, H. Edwards, I. Babuschkin, V. Misra, Grokking: Generalization beyond overfitting on small algorithmic datasets. arXiv:2201.02177 (2022).
9. N. Nanda, L. Chan, T. Lieberum, J. Smith, J. Steinhardt, Progress measures for grokking via mechanistic interpretability. Proc. ICLR (2023).
10. M. Belkin, D. Hsu, S. Ma, S. Mandal, Reconciling modern machine-learning practice and the classical bias–variance trade-off. Proc. Natl. Acad. Sci. U.S.A. 116, 15849–15854 (2019).
11. P. Nakkiran, G. Kaplun, Y. Bansal, T. Yang, B. Barak, I. Sutskever, Deep double descent: Where bigger models and more data hurt. Proc. ICLR (2020).
12. J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, R. Hadsell, Overcoming catastrophic forgetting in neural networks. Proc. Natl. Acad. Sci. U.S.A. 114, 3521–3526 (2017).
13. D. Lopez-Paz, M. A. Ranzato, Gradient episodic memory for continual learning. Adv. Neural Inf. Process. Syst. 30, 6467–6476 (2017).
14. M. Farajtabar, N. Azizan, A. Mott, A. Li, Orthogonal gradient descent for continual learning. Proc. Mach. Learn. Res. 108, 3762–3773 (2020).
15. A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser,

I. Polosukhin, Attention is all you need. Adv. Neural Inf. Process. Syst. 30, 5998–6008 (2017).

16. T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, D. Amodei, Language models are few-shot learners. Adv. Neural Inf. Process. Syst. 33 (2020).

17. J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. H. Chi, Q. V. Le, D. Zhou, Chain-of-thought prompting elicits reasoning in large language models. Adv. Neural Inf. Process. Syst. 35 (2022).

18. L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe, Training language models to follow instructions with human feedback. Adv. Neural Inf. Process. Syst. 35 (2022).

19. Q. Xie, M.-T. Luong, E. Hovy, Q. V. Le, Self-training with noisy student improves ImageNet classification. Proc. CVPR, 10687–10698 (2020).

20. I. Shumailov, Z. Shumaylov, Y. Zhao, N. Papernot, R. Anderson, Y. Gal, AI models collapse when trained on recursively generated data. Nature 631, 755–759 (2024).

21. G. Yang, E. J. Hu, Tensor programs IV: Feature learning in infinite-width neural networks. Proc. Mach. Learn. Res. 139, 11727–11737 (2021).

22. S. Jain, B. C. Wallace, Attention is not explanation. Proc. NAACL-HLT, 3543–3556 (2019). doi:10.18653/v1/N19-1357.

23. S. Wiegreffe, Y. Pinter, Attention is not not explanation. Proc. EMNLP-IJCNLP, 11–20 (2019). doi:10.18653/v1/D19-1002.

24. L. Dinh, R. Pascanu, S. Bengio, Y. Bengio, Sharp minima can generalize for deep nets. Proc. ICML, 1019–1028 (2017).

25. A. M. Saxe, Y. Bansal, J. Dapello, M. Advani, A. Kolchinsky, B. D. Tracey, D. D. Cox, On the information bottleneck theory of deep learning. Proc. ICLR (2018).

26. K. Kawaguchi, Z. Deng, X. Ji, J. Huang, How does information bottleneck help deep learning?. Proc. Mach. Learn. Res. 202, 16049–16096 (2023).

27. M. Gerstgrasser, R. Schaeffer, A. Dey, R. Rafailov, H. Sleight, J. Hughes, T. Korbak, R. Agrawal, D. Pai, A. Gromov, D. A. Roberts, D. Yang, D. L. Donoho, S. Koyejo, Is model collapse inevitable? Breaking the curse of recursion by accumulating real and synthetic data. ICML Workshop on Foundation Models in the Wild (2024).

# 投稿声明

**资金支持**。本研究未获得任何资金资助。

**作者贡献**。Mian Wang 提出研究构想；建立原子生成事实模型、生成事实图（GFG）、基于 GFG 的递归科学研究过程，以及训练—学习—推理—强化统一理论；确定科学问题、研究边界与决策标准；提出主要理论假设和概念转换；主导研究计划；分析并解释经过验证的结果；提出前瞻性预测和理论推导；制作图表；撰写并修改论文。

**利益冲突**。作者声明不存在利益冲突。

**数据、代码与材料可用性**。本研究的公开证据仓库按照论文的科学主张组织，旨在支持快速机器辅助审计（https://github.com/wind342/tlir-research-evidence/tree/codex/tlir-paper-evidence-navigation-v1）。论文—证据映射将主要科学主张、实验、图中子图和报告结果，与冻结协议、源代码、结果记录、来源及校验和清单、独立验证程序建立对应关系。公开证据矩阵还说明了哪些结果能够独立重新计算，以及哪些底层检查点或运行材料没有包含在公开发布的版本中。

**生成式人工智能的使用与贡献**。包括 OpenAI Codex 和 ChatGPT 在内的通用 AI 系统，在基于 GFG 的递归科学研究过程中充当科研代理。在作者的指导下，这些 AI 系统**发明并实现了四套实验仪器**——CSRG-4C、真实更新因果分叉仪器、有限幅度更新路径仪器和身份对齐目标边界账本——并且设计、实现、启动、监控和执行了论文报告的实验。AI 系统开展了分析、因果干预、匹配重放、反例搜索和独立验证，并参与论文起草、编辑和 LaTeX 排版。所有报告的数值结果均由记录在案的原生程序与执行环境产生，而非 AI 模型直接生成的文本。作者确定科学问题、研究边界和决策标准，审查经过验证的证据，并对科学主张与结果承担责任。